

Определения

- **Психологический словарь** - волевой акт формирования последовательности действий, ведущих к достижению цели на основе преобразования исходной информации в ситуации неопределенности.
- **Процесс принятия решений** - центральный на всех уровнях переработке информации и психической регуляции в системе целенаправленной деятельности.
- Принятие решений может выступать и как особая форма мыслительной деятельности (решение управленческое), и как один из этапов мыслительного действия при решении любых задач. Область применения этого понятия весьма широка. Кроме общей психологии она охватывает психологию управления, социальную психологию (групповое принятие решений), психофизиологию (процесс, переводящий афферентный синтез в программу действия), теорию игр и пр.
- **Афферентный синтез** - это первая стадия поведенческого акта в теории функциональных систем П.К. Анохина, представляющая собой процесс интеграции в центральной нервной системе (ЦНС) информации от внешних и внутренних сигналов (афферентаций), мотивационного возбуждения и памяти для принятия решения и формирования цели действия.
- Групповое принятие решений реализуемый группой выбор из ряда альтернатив в условиях взаимного обмена информацией при решении общей для всех членов группы задачи. Процедура принятия решений предполагает обязательное согласование мнений членов группы - в отличие от дискуссии, обычно рассматриваемой как фаза, предшествующая принятию решений.
- Большой толковый социологический словарь. **Принятие решений (decision making)** - процессы, посредством которых личности или группы и организации решаются на какие-либо действия либо определяют политику. Очевидно, что принятие решений охватывает широкую область, включающую фактически всякую человеческую деятельность. Социологи, психологи и политологи, помимо всех прочих, по-разному заинтересовались данным процессом, хотя их интересы часто пересекаются. Подходы включают формальный анализ стратегий принятия решений акторами в конкурирующих ситуациях (как в теории игр); анализ поведения, связанного с принятием решений, в динамике малых групп; изучение организаций; изучение доступа к политическому принятию решений.
- Энциклопедия социологии. Принятие решений - англ. *decision-making*; нем. *Entscheidung treffen*. Выбор одного из вариантов решения задачи или проблемы, в основе которой лежит информационное обеспечение и системный анализ ситуации. Субъективную основу оптимального процесса решения составляют ясное и беспристрастное представление и осмысление сложившейся ситуации, четкое

осознание собственных целей и наглядное прогнозирование развития будущих событий. Процедура процесса решения включает формирование и сопоставление альтернатив, выбор, построение и коррекцию гипотезы или программы действий.

- Толковый словарь по психологии. Общий термин, используемый для обозначения: 1. Процесса выбора. 2. Ряд теорий и исследований того, как организмы делают выбор между альтернативами. Основное внимание уделяется принятию решений человеком, и эта проблема считается областью внутри сферы исследований когнитивной психологии. То есть, процесс принятия решений - это процесс выбора одного из возможных вариантов решения задачи.

Процесс включает:

- постановку цели,
- поиск и оценку альтернатив,
- выбор и реализацию оптимального варианта.

Ключевые элементы процесса: проблема (ситуация, требующая решения), цель (что нужно достичь), альтернативы (варианты действий), критерии выбора (оценочные показатели или целевая функция) и лицо, принимающее решение (ЛПР). На практике это может быть менеджер, группа экспертов, а с развитием ИИ - совместная система «человек+машина»

Примеры: В управлении это могут быть решения о стратегическом развитии, распределении ресурсов, найме персонала и т.п.; в повседневной жизни - выбор покупки или планирование маршрута.

Уровни решений

Операционные: частые, структурированные, основанные на правилах.

Пример: Автоматическое пополнение запасов на складе при достижении порога.

Тактические

Среднесрочные, полуструктурированные.

Пример: Выбор поставщика на основе анализа цен, качества, надежности; оптимизация графика производства на месяц; определение целевых групп для маркетинговой кампании.

Стратегические

Долгосрочные, неструктурированные, высокий уровень неопределенности.

Пример: Выход на новый рынок; запуск принципиально нового продукта; выбор стратегического партнера; крупные инвестиции в ИТ-инфраструктуру. Здесь ИИ чаще всего предоставляет аналитику и прогнозы, но окончательное решение остается за человеком.

Комплексность и информационная перегрузка

Современный мир характеризуется большим объемом данных и быстрыми изменениями. По мере роста сложности проблем и объема информации растёт и потребность в системах поддержки принятия решений, основанных на передовых технологиях. Это видно из практики: руководителю нужно оперативно анализировать потоки данных (рынок, производство, медицину и т.д.) и принимать обоснованные решения.

Роль ИИ

Искусственный интеллект способен существенно усилить процесс принятия решений, повысить эффективность и точность. Благодаря большим данным и вычислительной мощности системы на основе ИИ могут обрабатывать сложные неструктурированные данные, делать прогнозы и выдавать рекомендации. Другими словами, ИИ помогает быстро и точно выявлять закономерности, которые не видны человеку

Стратегическая значимость

По оценкам экспертов, интеграция аналитики и ИИ для принятия стратегических решений - одна из главных задач руководителей. В государственных стратегиях (например, Указ Президента РФ №490 от 2019 г.) выделены национальные программы развития ИИ до 2030 года: перспективные системы поддержки решений должны базироваться на ИИ.

Возможность ИИ для поддержки решений

Анализ огромных объемов структурированных и неструктурированных данных (текст, изображения).

Выявление сложных, скрытых закономерностей и корреляций.

Прогнозирование будущих событий или трендов.

Генерация альтернатив и оценка их последствий.

Автоматизация рутинных этапов анализа.

Персонализация рекомендаций и решений.

Ограничения ИИ

Зависимость от данных: качество ИИ напрямую зависит от качества и репрезентативности данных. "Мусор на входе - мусор на выходе"

Пример: Данные могут содержать предубеждения.

Черный ящик

Сложность интерпретации решений сложных моделей (особенно глубокого обучения).

Отсутствие здравого смысла и глубокого понимания контекста

ИИ не понимает мир как человек.

Пример: Медицинская модель может корректно предсказать диагноз, но не понять нюансы состояния пациента или социальные факторы.

Трудности с уникальными ситуациями

ИИ обучен на прошлых данных и может плохо справляться с принципиально новыми сценариями.

Этические и социальные риски

Дискриминация, нарушение приватности, ответственность за решения.

Разница между автоматизацией и поддержкой решений

Автоматизация

Цель: полностью заменить человека на этапе исполнения рутинных, детерминированных задач.

Решение: предопределено правилами/алгоритмом. Нет выбора.

Примеры: Робот на конвейере, скрипт для резервного копирования, алгоритм для автоматического одобрения заявок на микрокредит по строгим критериям.

Поддержка решений (СППР)

Цель: усилить способность человека принимать решения, предоставляя информацию, анализ, прогнозы и рекомендации. Окончательное решение принимает человек.

Решение: человек выбирает из предложенных альтернатив или использует выводы системы для формирования своего решения. Неопределенность выше.

Примеры:

1. Система анализирует историю пациента, симптомы, результаты анализов и предлагает врачу возможные диагнозы с вероятностями и рекомендуемые обследования. Врач ставит окончательный диагноз и назначает лечение.
2. Система прогнозирует спрос на товары в разных магазинах и рекомендует менеджеру по закупкам объемы и сроки поставок. Менеджер учитывает дополнительные факторы (погода, акции конкурентов) и утверждает заказ.
3. Система оценивает риски инвестиционного проекта на основе рынка, финансовых показателей и макроэкономических данных, предоставляя аналитический отчет

инвестору. Инвестор принимает решение.

Классификация подходов к принятию решений (<https://it.rfei.ru/>)

- **Нормативные (прескриптивные) теории решений**
формальные, логические основы и правила;
рациональные, исполнимые заключения.
Использование математики, в особенности теоретической статистики
- **Описательные (дескриптивные) теории решений**
как и почему на практике решения принимаются так, а не иначе.
Использование знаний из области психологии социологии
- **Интегративные теории решений**
ЛПР стремится к объективным, рациональным результатам;
ЛПР учитывает субъективные ценности и неполноту информации.
Использование знаний из многих наук, в т.ч. математики, психологии и социологии

Эволюция систем поддержки принятия решений (СППР) и роль ИИ <https://habr.com/ru/articles/789146/>

СППР или цифровой советник - это программное обеспечение, которое используется для принятия решений в сложных ситуациях. Ключевая задача - анализ данных в сложных условиях и подготовка рекомендаций.

Работать может на основе таких технологий как:

- нейросети и машинное обучение;
- большие данные и сквозная аналитика;
- интернет вещей;
- облачные вычисления;
- теория игр, теория ограничения систем;
- системы правил на основе экспертных знаний.

История (необязательно)

Первые концепции **DSS (Decision Support System)** появились в конце 1960-х - начале 1970-х годов из практики управленческого учета и баз данных. Например, в 1974 года термин **MIS (Management Information System)** определился как «интегрированная человеко-машинная система обеспечения информацией, поддерживающая функции операций, менеджмента и принятия решений в организации». Это стало основой для СППР - систем, которые не только хранят данные, но и дают возможность их анализировать.

1970-1980-е: появление модель-ориентированных СППР, основанных на аналитических и статистических моделях.

В **1981 году** была разработана концепция **EIS (Executive Information System)** - системы для топ-менеджера, аккумулирующей критические показатели.

1990-е: бурное развитие технологий хранения и обработки данных: Data Warehouses OLAP (многомерный анализ данных) СППР становятся «Bi-системами» (Business Intelligence).

2000-е и далее: системы на основе веб-технологий и масштабируемых хранилищ, интеграция больших данных. Развитие ИТ-платформ и облачных решений (Saas) сделало СППР более доступными.

Современный этап - включение в СППР методов ИИ и машинного обучения. Если раньше СППР опирались на правила и модели, то сейчас они используют нейросети, генетические алгоритмы, аналитику больших данных. При этом часто говорят об интеллектуализированной СППР (ИСППР) - когда ИИ является ядром системы. Такие системы могут давать адаптивные рекомендации, обучаться на предыдущем опыте и обрабатывать неструктурированные данные (тексты, изображения и пр.).

Области применения СППР

- принятие решение и формирование лечебных протоколов в здравоохранении;
- расчет цен и согласование потребностей;
- оптимизации цепочек поставок;
- принятие решение о предоставлении кредитов;
- страхование;
- прогнозы по выручке и рентабельности;
- предсказание природных катаклизмов и рекомендации по мерам их предотвращения или ликвидации;
- оптимизация продуктовых линеек, программ лояльности и минимизация оттока клиентов;
- планирование закупок и хранения и т.д.

Примеры СППР на основе ИИ

- **Рекомендательные системы:** предложить пользователю релевантные товары/контент/действия.
Например, Netflix (фильмы), Spotify (музыка), Amazon (товары), Linkedin (вакансии, контакты).
- **Системы прогнозирования:** предсказать будущее значение показателя.
Например, провоз спроса на товар услуги, провоз стока клиентов, прогноз цен на акции/сырье, прогноз погоды, прогноз вероятности заболевания.

- **Классификаторы:** отнести объект к одному из predetermined классов.
Например, фильтрация спама, определение категории новости/документа, оценка кредитного риска (одобрить/отклонить/требуется проверка), диагностика заболеваний по снимкам (напр., рак), анализ тональности ОТЗЫВОВ.
- **Системы обнаружения аномалий:** выявить необычные, подозрительные или редкие события.
Например, обнаружение мошеннических транзакций, обнаружение сбоев оборудования, выявление кибератак, контроль качества на производстве.

Теоретические основы принятия решений

Математическая модель принятия решений - это формализованное представление процесса выбора, включающее множество альтернатив, состояний среды, исходов и критериев оценки.

фон Нейман и Моргенштерн «Теория игр и экономическое поведение»: математическая формализация позволяет перейти от интуитивных суждений к строгим количественным методам анализа.

Ключевые элементы модели

- $A = \{a_1, a_2, \dots, a_n\}$ - множество альтернатив (возможных решений)
- $S = \{s_1, s_2, \dots, s_m\}$ - множество состояний среды (внешних условий)
- $X = \{x_{11}, x_{12}, \dots, x_{nm}\}$ - множество исходов (результатов решений)
- $U: X \rightarrow R$ - функция полезности, отображающая исходы в числовые значения

Пример: Задача выбора инвестиционной стратегии

- **Альтернативы (A):**
 a_1 : Консервативная стратегия (государственные облигации)
 a_2 : Умеренная стратегия (смешанный портфель)
 a_3 : Агрессивная стратегия (акции роста)
- **Состояния среды (S):**
 s_1 : Экономический рост (вероятность 0.4)
 s_2 : Стагнация (вероятность 0.4)
 s_3 : Рецессия (вероятность 0.2)
- **Матрица исходов (доходность в %):**

	s_1 (рост)	s_2 (стагн.)	s_3 (рецес.)
a_1 (консерв.)	3%	2%	1%
a_2 (умерен.)	8%	4%	-2%

	s_1 (рост)	s_2 (стагн.)	s_3 (рецес.)
a_3 (агрессив.)	15%	2%	-10%

Полезность (utility) - это числовая мера предпочтений лица, принимающего решение.

Функция полезности $U(x)$ присваивает каждому исходу x числовое значение таким образом, что более предпочтительные исходы получают большие значения.

Основные свойства функции полезности:

1. **Полнота:** для любых двух исходов x и y либо $U(x) \geq U(y)$, либо $U(y) \geq U(x)$
2. **Транзитивность:** если $U(x) \geq U(y)$ и $U(y) \geq U(z)$, то $U(x) \geq U(z)$
3. **Непрерывность:** небольшие изменения в исходах ведут к небольшим изменениям в полезности

Пример: Функция полезности для медицинского решения

- **Альтернативы:**

a_1 : Медикаментозное лечение

a_2 : Малоинвазивная операция

a_3 : Открытая операция на сердце

- **Критерии оценки и их веса:**

Выживаемость пациента (вес 0.6)

Качество жизни после лечения (вес 0.3)

Стоимость лечения (вес 0.1)

Функция полезности: $U(\text{исход}) = 0.6 \times (\text{вероятность выживания}) + 0.3 \times (\text{индекс качества жизни}) + 0.1 \times (1 - \text{нормированная стоимость})$

Для медикаментозного лечения:

$$U(a_1) = 0.6 \times 0.85 + 0.3 \times 0.70 + 0.1 \times 0.90 = 0.51 + 0.21 + 0.09 = 0.81$$

Принятие решений в условиях риска

Когда вероятности состояний среды известны, оптимальное решение выбирается по критерию *максимизации ожидаемой полезности*:

$$EU(a_i) = \sum_j P(s_j) \times U(x_{ij}),$$

где $P(s_j)$ - вероятность состояния s_j , $U(x_{ij})$ - полезность исхода при выборе альтернативы a_i в состоянии s_j .

Пример: Решение о запуске нового продукта

- **Альтернативы:**

a_1 : Запустить немедленно (инвестиции 2 млн руб.)

a_2 : Провести дополнительное тестирование (инвестиции 2.5 млн руб.)

a_3 : Отказаться от запуска

- **Состояния рынка:**

s_1 : Высокий спрос ($P = 0.3$)

s_2 : Средний спрос ($P = 0.5$)

s_3 : Низкий спрос ($P = 0.2$)

- **Матрица прибылей (млн руб.):**

	s_1 (высокая)	s_2 (средняя)	s_3 (низкая)
a_1 (немедленно)	8	3	-1
a_2 (с тестированием)	7	4	1
a_3 (отказ)	0	0	0

Расчет ожидаемой полезности:


$EU(a_1) = 0.3 \times 8 + 0.5 \times 3 + 0.2 \times (-1) = 2.4 + 1.5 - 0.2 = 3.7$ млн руб.

$EU(a_2) = 0.3 \times 7 + 0.5 \times 4 + 0.2 \times 1 = 2.1 + 2.0 + 0.2 = 4.3$ млн руб.

$EU(a_3) = 0$

Оптимальное решение: a_2 (дополнительное тестирование)

Дерево решений с ожидаемыми значениями (EV) приведенных результатов (долл.)



Принятие решений в условиях неопределенности

Когда вероятности состояний среды неизвестны, используются различные критерии:

- **Критерий Вальда (максимин).** Выбирается альтернатива с наилучшим из наихудших исходов: $ai^* = \arg \max \min x_{ij}$
- **Критерий максимакса.** Выбирается альтернатива с наилучшим из наилучших исходов: $ai^* = \arg \max \max x_{ij}$
- **Критерий Гурвица.** Компромисс между оптимизмом и пессимизмом:
 $H(ai) = \alpha * \max(x_{ij}) + (1 - \alpha) * \min(x_{ij})$, где $\alpha \in [0, 1]$ – коэффициент оптимизма
- **Критерий Сэвиджа (минимакс сожалений).** Минимизируется максимальное сожаление (упущенная выгода).

Пример: Выбор поставщика сырья в условиях неопределённости

Производственная компания выбирает поставщика сырья на следующий год, не зная точно, как изменятся цены.

Альтернативы:

- a_1 : Долгосрочный контракт с фиксированной ценой
 - a_2 : Краткосрочные контракты с переменной ценой
 - a_3 : Создание собственного производства сырья
- Возможные сценарии цен на сырьё:
- s_1 : Цены растут значительно
 - s_2 : Цены стабильны
 - s_3 : Цены падают

	s_1 (рост)	s_2 (стабильность)	s_3 (падение)
a_1 (долгосрочные)	50	50	50
a_2 (краткосрочные)	70	45	30
a_3 (собственные)	55	55	55

Критерии:

- **Критерий Вальда (максимин затрат = минимакс):**
 $\min a_1 = 50, \min a_2 = 30, \min a_3 = 55$
Выбирается a_3 (наименьшие максимальные затраты)
- **Критерий максимакса (минимин затрат):**
 $\max a_1 = 50, \max a_2 = 70, \max a_3 = 55$
Выбирается a_1 (наименьшие минимальные затраты)

- **Критерий Гурвица** ($\alpha = 0.6$):

$$H(a_1) = 0.6 * 50 + 0.4 * 50 = 50$$

$$H(a_2) = 0.6 * 30 + 0.4 * 70 = 46$$

$$H(a_3) = 0.6 * 55 + 0.4 * 55 = 55$$

Выбирается a_2

Анализ чувствительности и оценка рисков

Анализ чувствительности позволяет оценить, как изменения в параметрах модели (вероятности, полезности) влияют на оптимальное решение. Это критически важно для понимания устойчивости принятого решения.

Пример: Анализ чувствительности для фармацевтической компании

Компания решает, стоит ли инвестировать в разработку нового лекарства.

Базовый сценарий:

Вероятность успеха клинических испытаний: **0.4**

Прибыль при успехе: **500** млн руб.

Убытки при неудаче: **-100** млн руб.

Ожидаемая прибыль: $0.4 * 500 + 0.6 * (-100) = 140$ млн руб.

Анализ чувствительности по вероятности успеха:

Пусть p - вероятность успеха.

Проект выгоден, если: $p * 500 + (1 - p) * (-100) > 0$

$$500p - 100 + 100p > 0$$

$$600p > 100$$

$$p > 1/6 = 0.67$$

Вывод: проект остается выгодным даже при снижении вероятности успеха до **16.7%**

Меры риска

1. Дисперсия исходов: $Var(X) = E[(X - E[X])^2]$
2. Стандартное отклонение: $\sigma = \sqrt{Var(X)}$
3. Value at Risk (VaR): максимальные потери с заданной вероятностью
4. Conditional Value at Risk ($CVaR$): ожидаемые потери при превышении VaR

Отклонения от нормативной модели

Реальное поведение людей часто отклоняется от предписаний теории ожидаемой полезности:

1. Эвристики и систематические ошибки
2. Эффект фреймирования (как формулировка влияет на выбор)

3. Неприятие потерь (потери воспринимаются острее выигрышей)
4. Гиперболическое дисконтирование (переоценка ближайшего будущего)

Пример: Эффект фреймирования в медицинских решениях

Задача Канемана и Тверски: Представьте, что готовится программа борьбы с эпидемией, которая может унести **600** жизней.

Фрейм 1 (акцент на спасенных жизнях)

Программа А: 200 человек будут спасены точно.

Программа В: с вероятностью 1/3 будут спасены 600 человек, с вероятностью 2/3 – никто.

Фрейм 2 (акцент на потерянных жизнях)

Программа С: 400 человек погибнут точно.

Программа D: с вероятностью 1/3 никто не погибнет, с вероятностью 2/3 погибнут 600 человек.

Результат экспериментов:

- В первом фрейме большинство выбирают А (неприятие риска)
- Во втором фрейме большинство выбирают D (принятие риска)

При этом $A = C$ и $B = D$ математически!

Источник: Kahneman, D., & Tversky, A. (1984). Choices, Values, and Frames. *American Psychologist*, 39(4), 341-350.

Архитектура и эволюция СППР

Эволюция СППР началась в 1960-х с MIS (системы управления информацией), перешла в 1970-е к модель-ориентированным DSS (интеграция аналитики), в 1980-х к EIS (системы для топ - менеджеров с дашбордами). В 1990-х появились Data Warehouses и OLAP для многомерного анализа, а в 2000-х — интеграция больших данных и облачных технологий (BI — системы). Современный этап - переход к интеллектуальным DSS с ИИ. То есть от статических отчётов постепенно перешли к динамическим рекомендациям.

Пример

Ранние СППР, такие как GADS (Generalized Audit Decision System, 1970-е), использовали простые правила и алгоритмы для автоматизации аудита финансовых отчетов в компаниях, где система проверяла соответствие транзакций нормам, генерируя отчеты о несоответствиях без глубокого анализа. Современные системы применяют машинное обучение для персонализированных рекомендаций товаров, анализируя поведение

миллионов пользователей в реальном времени.

Например (из отчетов Amazon), если пользователь просмотрел товар А с вероятностью покупки **0.8** и полезностью **+50**, ожидаемая полезность = $0.8 * 50 = 40$. Система интегрирует это с данными о похожих пользователях, оптимизируя отображение товаров, что повышает продажи на **35%**.

Предпосылки появления СППР и формализация концепции (1960-1980е гг.)

Традиционные информационные системы управления фокусировались на предоставлении отчетов и структурированной информации. Менеджерам требовались инструменты для анализа альтернатив и моделирования сценариев.

Keen (1978): «СППР (DSS) представляют собой класс информационных систем, которые поддерживают деятельность по принятию решений»

Система BRANDAID, разработанная в **1970х** для Procter & Gamble, помогала менеджерам по маркетингу принимать решения о рекламном бюджете и стратегии продвижения товаров.

Система включала модели потребительского поведения, позволяя симулировать реакцию рынка на различные маркетинговые стратегии и оптимизировать распределение бюджета между рекламными каналами.

В **1971** году компания Lockheed разработала систему GPLAN для планирования производства, которая позволяла менеджерам моделировать различные производственные сценарии и оценивать их влияние на прибыльность. Система могла обрабатывать данные о ресурсах, заказах и ограничениях, предоставляя руководству альтернативные планы производства с оценкой рисков и доходности каждого варианта. Gorry и Scott-Morton (1971) предложили матрицу решений, классифицирующую задачи управления по степени структурированности и уровню управления.

В **1978** году Джином Кином и Майклом Мортонем была сформулирована классическая концепция DSS как интерактивных компьютерных систем, помогающих лицам, принимающим решения, использовать данные и модели для решения слабоструктурированных проблем.

Архитектура и основные компоненты традиционных СППР

Трёхкомпонентная архитектура СППР

Классическая архитектура СППР включает три основных компонента:

- а) подсистему управления данными (DNS),
- б) подсистему управления моделями (MBMS)
- в) подсистему управления диалогом (DGMS).

Эта архитектура была предложена Sprague и Carlson (1982) и остается основой для понимания структуры СППР.

Пример

Финансовая СППР банка включает:

1. базу данных с информацией о клиентах, кредитах и рыночных показателях;
2. модели оценки кредитного риска, портфельного анализа и прогнозирования;
3. пользовательский интерфейс с дашбордами, позволяющими кредитному аналитику визуализировать риск-профили заемщиков, моделировать сценарии изменения процентных ставок и генерировать отчеты для принятия решений о выдаче кредитов.

Архитектура и основные компоненты традиционных СППР

Подсистема управления данными (Database Management Subsystem)

Включает системы управления базами данных, хранилища данных и средства извлечения информации.

Современные СППР используют концепцию хранилища данных (Data Warehouse), интегрирующего информацию из различных операционных систем.

Immon (1996) определяет хранилище данных как «предметно-ориентированную, интегрированную, неизменяемую и привязанную ко времени коллекцию данных для поддержки принятия управленческих решений»

Пример

Система управления цепочками поставок Walmart интегрирует данные от тысяч поставщиков, складов и магазинов в единое хранилище.

СППР анализирует паттерны продаж, сезонные колебания и поведение потребителей, позволяя менеджерам оптимизировать запасы, планировать закупки и минимизировать затраты на логистику при обеспечении высокого уровня сервиса.

Архитектура и основные компоненты традиционных СППР

Подсистема управления моделями (Model-Base Management Subsystem)

Содержит математические, статистические и эвристические модели для анализа данных и генерации альтернатив решений.

Модели могут быть оптимизационными симуляционными (Монте-Карло), прогнозными (временные ряды) или финансовыми (NPV, DCF).

Пример

Авиакомпания использует СППР с моделью оптимизации маршрутной сети, которая учитывает спрос пассажиров, стоимость топлива, ограничения аэропортов и конкуренцию.

Система позволяет планировщикам моделировать различные конфигурации маршрутов, оценивать прибыльность новых направлений и оптимизировать расписание полетов для максимизации загрузки и доходности.

Ограничения традиционных DSS и потребность в привлечении ИИ

Традиционные DSS эффективны для структурированных задач, но имеют ограничения при работе с неструктурированными данными, нечеткой логикой и обучением на опыте. Turban и Watkins (1986): есть необходимость в системах, способных к рассуждению, обучению и адаптации к изменяющимся условиям.

Пример

Традиционная СППР для управления складом может оптимизировать размещение товаров на основе заданных правил и исторических данных.

СППР с использованием машинного обучения способна анализировать паттерны спроса в реальном времени, учитывать внешние факторы (погоду, события, тренды социальных сетей) и динамически корректировать стратегию размещения для минимизации времени сборки заказов.

Интеллектуальные СППР интегрируют методы ИИ для обработки знаний, рассуждения в условиях неопределенности и адаптивного обучения.

Marakas (2003): СППР это «системы, использующие методы ИИ для решения проблем, которые обычно требуют человеческого опыта и интуиции».

Пример: Медицинская IDSS IBM Watson for Oncology анализирует медицинскую литературу, данные пациентов и клинические протоколы для рекомендации персонализированных планов лечения рака. Система использует обработку естественного языка для анализа тысяч медицинских публикаций, машинное обучение для выявления паттернов в данных пациентов и экспертные системы для применения клинических правил при формировании рекомендаций.

Замечание

Экспертная система (ЭС) - это информационная система, назначение которой частично или полностью заменить эксперта в той или иной предметной области.

Данные — это совокупность фактов и идей представленных в формализованном виде. Собственно на данных основываются закономерности для предсказания,

прогнозирования.

Знания — это правила, законы, закономерности полученные в результате профессиональной деятельности в пределах предметной области.

База знаний — база данных содержащая правила вывода и информацию о человеческом опыте и знаниях в некоторой предметной области. Другими словами, это набор таких закономерностей, которые устанавливают связи между вводимой и выводимой информацией.

Преимущества СППР с ИИ

Интеллектуальные СППР обеспечивают повышение качества решений за счет анализа больших данных, ускорение процесса принятия решений, снижение человеческих ошибок и способность работать с неопределенностью и неполной информацией.

Например, логистическая интеллектуальная СППР компании DHL анализирует данные о заказах, трафике, погодных условиях и работе складов для оптимизации маршрутов доставки. Система сократила время доставки на 15%, снизила расход топлива на 12% и повысила удовлетворенность клиентов. Интеграция машинного обучения позволила системе адаптироваться к сезонным колебаниям спроса и непредвиденным событиям (дорожные работы, забастовки).

Проблемы СППР с ИИ

- Проблемы интерпретируемости решений ("черный ящик")
- Требования к качеству и объему данных
- Необходимость в специализированных кадрах, высокие затраты на разработку и внедрение
- Этические и правовые вопросы использования ИИ.

Например, банк отказался от использования нейросетевой модели для кредитного скоринга после того, как регулятор потребовал объяснения каждого решения об отказе в кредите. Модель показывала высокую точность, но не могла предоставить понятные объяснения своих решений. Банк вернулся к гибридной системе, комбинирующей интерпретируемые правила с машинным обучением, что снизило точность на 3%, но обеспечило требуемую прозрачность.

Тенденции развития и будущие направления

- Создание более интерпретируемых моделей
- Интеграция с облачными платформами
- Развитие человеко-машинного взаимодействия и создание автономных интеллектуальных агентов.

Например, система предоставляет рекомендации с объяснениями, человек может корректировать параметры и ограничения, а система учится на обратной связи. Такой подход реализован в системе подбора персонала LinkedIn, где рекрутер может корректировать веса различных критериев отбора, а алгоритм адаптирует рекомендации к предпочтениям конкретного рекрутера.

Примеры использования СППР с ИИ

Финансы: системы управления рисками и инвестициями

Финансовые СППР с ИИ анализируют рыночные данные, оценивают риски, оптимизируют портфели и выявляют мошеннические операции. Они обрабатывают большие объемы данных в реальном времени и адаптируются к изменяющимся рыночным условиям.

Например, система управления кредитными рисками банка использует ансамбли машинного обучения для скоринга заемщиков. Система анализирует традиционные финансовые данные, альтернативные источники (социальные сети, мобильные платежи, геолокация) и макроэкономические показатели. Модели непрерывно переобучаются на новых данных, адаптируясь к изменениям в экономике. Система предоставляет не только скоринговую оценку, но и объяснения ключевых факторов риска.

Производство

Производственные СППР с ИИ интегрируются с IoT-датчиками для мониторинга оборудования, оптимизации процессов и предиктивного обслуживания. Они анализируют данные в реальном времени и принимают тое решения.

Например, система предиктивного обслуживания на химическом заводе анализирует данные с тысяч датчиков (температура, давление, вибрация, состав продукта) для прогнозирования отказов оборудования. Машинное обучение выявляет паттерны, предшествующие поломкам, за 2-4 недели до их возникновения. Система автоматически формирует заявки на техническое обслуживание, заказывает запчасти и планирует остановки производства для минимизации простоев.

Многокритериальный анализ решений (MCDA)

MCDA – Представляет собой набор методов и процедур для структурирования и решения проблем с множественными, часто конфликтующими критериями.

Почему нужен MCDA?

Реальные задачи включают множество критериев: стоимость, риск, устойчивость. MCDA позволяет формализовать предпочтения и выработать рациональное решение.

Пример. Городская администрация выбирает место для строительства нового

медицинского центра.

Критерии:

- доступность для населения (максимизация расстояния до жителей),
- близость к транспортным узлам (максимизация),
- экологическое воздействие (минимизация),
 - время строительства (минимизация).

Ни один из вариантов не является лучшим по всем критериям одновременно, требуется компромиссное решение с учетом приоритетов заинтересованных сторон.

Отличие от однокритериальной оптимизации

В однокритериальных задачах существует четкая целевая функция для оптимизации. В многокритериальных проблемах необходимо найти компромисс между несколькими, часто противоречивыми целями.

Вообще множественные цели являются правилом, а не исключением в принятии решений.

Пример. Инвестор выбирает финансовый портфель, стремясь одновременно максимизировать доходность и минимизировать риск.

Эти цели конфликтуют: более высокая доходность обычно связана с более высоким риском.

Портфель из государственных облигаций дает доходность 3% годовых при минимальном риске, портфель акций технологических компаний может дать 15% при высоком риске, сбалансированный портфель дает 8% при умеренном риске. Выбор зависит от предпочтений инвестора относительно соотношения риск-доходность.

Основное понятие MCDA

Альтернативы $A = \{a_1, a_2, \dots, a_n\}$

Критерии $C = \{c_1, c_2, \dots, c_m\}$

Веса w_i

Матрица оценок $X = [x_{ij}]$

Цель – нахождение альтернативы с наилучшей совокупной оценкой.

Классификация методов МСДА

Компенсационные - позволяют «компенсировать» слабое значение по одному критерию сильным по другому. WSM, AHP, TOPSIS.

Некомпенсационные - не допускают компенсации. ELECTRE, PROMETHEE

Гибридные - комбинируют оба подхода Fuzzy AHP, AHP-TOPSIS

Метод взвешенной суммы (WSM)

$$s(a_j) = \sum_{i=1}^n w_i x_{ij}$$

Пример: выбор ИТ-платформы по 3 критериям: производительность (вес 0.5), цена (вес 0.3), поддержка (вес 0.2).

Альтернатива	Производительность	Стоимость	Поддержка
A1	0.9	0.7	0.6
A2	0.8	0.9	0.8
A3	0.7	0.8	0.9

$$S(A_1) = 0.5 \times 0.9 + 0.3 \times 0.7 + 0.2 \times 0.6 = 0.78$$

$$S(A_2) = 0.82$$

$$S(A_3) = 0.79$$

Лучший вариант: A_2

Метод АНР (анализ иерархий, Analytic Hierarchy Process, Saaty, 1980)

Метод анализа иерархий (Analytic Hierarchy Process, АНР), разработанный Саати (Saaty, 1980), является одним из наиболее популярных методов MCDA.

Этапы:

1. Построение иерархии целей и критериев
2. Попарное сравнение элементов
3. Вычисление весов (собственные векторы)
4. Проверка согласованности

Построение иерархии

Метод структурирует задачу в виде иерархии: цель → критерии → подкритерии → альтернативы, и использует попарные сравнения для определения приоритетов.

Пример. Компания выбирает ERP-систему. Иерархия включает:

- цель (выбор оптимальной ERP) на верхнем уровне;
- критерии первого уровня (функциональность, стоимость, надежность, поддержка);
- подкритерии для функциональности (управление финансами, производством, персоналом, логистикой);
- альтернативы на нижнем уровне (SAP, Oracle, Microsoft Dynamics, 1C).

Структурирование задачи в иерархию делает сложную проблему более управляемой и позволяет систематически оценивать варианты.

Процедура попарных сравнений

Ключевая особенность АНР – использование попарных сравнений для определения весов. Эксперт сравнивает элементы попарно по шкале от 1 (равная важность) до 9 (абсолютное превосходство). Формируется матрица попарных сравнений, из которой вычисляются приоритеты.

Пример. При выборе локации для производственного предприятия сравниваются три критерия: стоимость земли, доступ к трудовым ресурсам, близость к рынкам сбыта.

Эксперт оценивает:

Стоимость земли умеренно важнее доступа к труду (оценка 3), доступ к труду равноценен близости к рынкам (оценка 1), стоимость земли немного важнее близости к рынкам (оценка 2).

Составляется матрица 3×3, вычисляется вектор, дающий веса критериев: стоимость 0.54, доступ к труду 0.26, близость к рынкам.

Проверка согласованности суждений

АНР включает проверку согласованности суждений через индекс согласованности (CI) и отношение согласованности (CR).

Если $CR > 0.10$, суждения считаются несогласованными и требуют пересмотра. Это защищает от логических противоречий типа $A > B$, $B > C$, но $C > A$.

Пример. Эксперт оценивает три инвестиционных проекта по доходности:

- проект А значительно доходнее В (оценка 5),
- В умеренно доходнее С (оценка 3), но С оценивается как равный А (оценка 1).

Это противоречиво: если $A \gg B$ и $B > C$, то А должен быть существенно доходнее С.

Расчет показывает $CR=0.18 (>0.10)$, что сигнализирует о несогласованности. Эксперту предлагается пересмотреть оценки для обеспечения логической непротиворечивости суждений.

Пример

Постановка задачи

Цель: Выбрать лучшего кандидата на позицию Senior Developer.

Критерии:

1. Технические навыки (Technical Skills)
2. Опыт работы (Experience)
3. Коммуникативные навыки (Communication Skills)
4. Личностные качества (Personality Fit)

Альтернативы (Кандидаты):

- Кандидат А
- Кандидат В
- Кандидат С

Шаг 1: Попарное сравнение критериев

Используем шкалу Саати от 1 до 9:

1 - равная важность

3 – умеренное превосходство

5 – сильное превосходство

7 – очень сильное превосходство

9 – абсолютное превосходство

Матрица попарных сравнений критериев:

Критерий	Technical	Experience	Communication	Personality
Technical	1	3	5	7
Experience	1/3	1	3	5
Communication	1/5	1/3	1	3
Personality	1/7	1/5	1/3	1

Шаг 2. Расчет весов критериев

а) Нормализация матрицы

Суммы по столбцам:

Technical: $1 + 1/3 + 1/5 + 1/7 = 1 + 0.333 + 0.2 + 0.143 = 1.676$

Experience: $3 + 1 + 1/3 + 1/5 = 3 + 1 + 0.333 + 0.2 = 4.533$

Communication: $5 + 3 + 1 + 1/3 = 5 + 3 + 1 + 0.333 = 9.333$

Personality: $7 + 5 + 3 + 1 = 16$

Нормализованная матрицы (делим каждый элемент на сумму столбца):

Критерий	Technical	Experience	Communication	Personality	Среднее
Technical	0.597	0.662	0.536	0.438	0.558
Experience	0.199	0.221	0.321	0.313	0.263
Communication**	0.119	0.073	0.107	0.188	**0.122
Personality	0.085	0.044	0.036	0.063	0.057

Веса критериев:

Technical: 0.558

Experience: 0.263

Communication: 0.122

Personality: 0.057

Шаг 3. Парное сравнение кандидатов по каждому критерию

Критерий 1: Techincal Skills

Кандидат	A	B	C
A	1	1/3	1/5
B	3	1	1/2
C	5	2	1

Суммы столбцов: A: 9, B: 3.333, C: 1.7

Нормализация и расчет весов:

Кандидат	A	B	C	Среднее
A	0.111	0.100	0.118	0.110
B	0.333	0.300	0.294	0.309
C	0.556	0.600	0.588	0.581

Веса по Technical Skills: A:0.110, B=0.309, C=0.581

Критерий 2: Experience

Кандидат	A	B	C
A	1	1/2	1/3
B	2	1	1/2
C	3	2	1

Суммы столбцов: A:6, B:3.5, C: 1.833

Нормализация и расчет весов:

Кандидат	A	B	C	Среднее
A	0.167	0.143	0.182	0.164

Кандидат	A	B	C	Среднее
B	0.333	0.286	0.273	0.297
C	0.500	0.571	0.545	0.539

Веса по Experience: A=0.164, B=0.297, C=0.539

Критерий 3: Communication Skills

Кандидат	A	B	C
A	1	3	5
B	1/3	1	2
C	1/5	1/2	1

Суммы столбцов: A:1.533, B:4.5, C:8

Нормализация в расчет весов:

Кандидат	A	B	C	Среднее
A	0.652	0.667	0.625	0.648
B	0.217	0.222	0.250	0.230
C	0.130	0.111	0.125	0.122

Веса по Communication: A=0.648, B=0.230, C=0.122

Критерий 4: Personality Fit

Кандидат	A	B	C
A	1	1/2	1/4
B	2	1	1/2
C	4	2	1

Суммы столбцов: A:7, B: 3.5, C: 1.75

Нормализация и расчет весов:

Кандидат	A	B	C	Среднее	
A	0.143	0.143	0.143	0.143	
B	0.286	0.286	0.286	0.286	

Кандидат	A	B	C	Среднее	
C	0.571	0.571	0.571	0.571	

Веса по Personality: A=0.143, B=0.286, C=0.571

Шаг 4: Расчет итоговых оценок

Матрицы решений:

Кандидат	Technical (0.558)	Experience (0.263)	Communication (0.122)	Personality (0.057)	Итог
A	$0.110 \times 0.558 = 0.061$	$0.164 \times 0.263 = 0.043$	$0.648 \times 0.122 = 0.079$	$0.143 \times 0.057 = 0.008$	0.191
B	$0.309 \times 0.558 = 0.172$	$0.297 \times 0.263 = 0.078$	$0.539 \times 0.122 = 0.038$	$0.571 \times 0.057 = 0.033$	0.349
C	$0.581 \times 0.558 = 0.324$	$0.539 \times 0.263 = 0.142$	$0.122 \times 0.122 = 0.015$	$0.571 \times 0.057 = 0.033$	0.514

Шаг 5: Ранжирование и вывод

Кандидат	Итоговая оценка	Ранг
Кандидат C	0.510	1
Кандидат B	0.349	2
Кандидат A	0.191	3

Согласно методу АНР, **наилучшим кандидатом является Кандидат С** с итоговой оценкой 0.514. Он показал наилучшие результаты по техническим навыкам и опыту работы, которые являются наиболее важными критериями в данной задаче.

Преимущество АНР: Метод позволяет учитывать не только абсолютные оценки по критериям, но и относительную важность самих критериев, что делает его особенно полезным для сложных многокритериальных задач с субъективными оценками.

Метод TOPSIS (Technique for Order Preference by Similarity to Ideal Solution, Hwang & Yoon, 1981)

- Идея: выбрать альтернативу, ближайшую к идеальной и далекую от антиидеальной.
- Метод вычисляет евклидовы расстояния до идеальной и антиидеальной точек и ранжирует альтернативы по относительной близости

Этапы:

1. Нормировка матрицы решений
2. Взвешивание - умножение на веса
3. Определение идеального и антиидеального решения
4. Вычисление относительной близости

Цель: Выбрать лучшего поставщика для компании.

Критерии оценки:

Цена (C1): Стоимость товара. Чем меньше, тем лучше. (Минимизирующий критерий)
лучше. (Максимизирующий критерий)

Качество (C2): Оценка качества товара по 100-балльной шкале. Чем больше, тем лучше. (Минимизирующий критерий)

Срок поставки (C3): Время поставки в днях. Чем меньше, тем лучше.
(Минимизирующий критерий)

Надежность (C4): Рейтинг надежности поставщика по 10-балльной шкале. Чем больше, тем лучше. (Максимизирующий критерий)

Альтернативы (Поставщики): A1, A2, A3, A4

Веса критериев: Предположим, все критерии одинаково важны. $W=(0.25,0.25,0.25, 0.25)$.

Матрица решений: Исходные данные по каждому поставщику и критерию.

Поставщик	Цена (C1), \$	Качество (C2), баллы	Срок поставки (C3), дни	Надежность (C4), баллы
A1	200	90	10	8
A2	250	80	8	7
A3	190	85	12	9
A4	270	70	9	6

Шаг 1: Нормализация матрицы решений

Мы нормализуем исходную матрицу, чтобы избавиться от единиц измерения. Используем метод квадратного корня.

Рассчитаем знаменатель для каждого критерия (корень из суммы квадратов всех значений по столбцу):

- C1: 459.89
- C2: 163.17
- C3: 19.72

- С4: 15.16

Теперь каждое значение в матрице делим на соответствующее число.

Поставщик	С1	С2	С3	С4
A1	0.435	0.552	0.507	0.528
A2	0.544	0.490	0.406	0.462
A3	0.413	0.521	0.609	0.594
A4	0.587	0.429	0.456	0.396

Шаг 2: Расчет взвешенной нормализованной матрицы

Умножаем каждый столбец нормализованной матрицы на вес соответствующего критерия

Поставщик	С1	С2	С3	С4
A1	$0.25 * 0.435 = 0.109$	$0.25 * 0.552 = 0.138$	$0.25 * 0.507 = 0.127$	$0.25 * 0.528 = 0.132$
A2	$0.25 * 0.544 = 0.136$	$0.25 * 0.490 = 0.123$	$0.25 * 0.406 = 0.102$	$0.25 * 0.462 = 0.116$
A3	$0.25 * 0.413 = 0.103$	$0.25 * 0.521 = 0.130$	$0.25 * 0.609 = 0.152$	$0.25 * 0.594 = 0.149$
A4	$0.25 * 0.587 = 0.147$	$0.25 * 0.429 = 0.107$	$0.25 * 0.456 = 0.114$	$0.25 * 0.396 = 0.099$

Шаг 3: Определение идеального (A+) и наихудшего (A-) решений

Идеальное решение (A+): Для минимизирующих критериев (С1, С3) берем **минимум** по столбцу. Для максимизирующих (С2, С4) – **максимум**.

Наихудшее решение (A-): Наоборот. Для минимизирующих критериев - **максимум**, для максимизирующих - **минимум**.

Поставщик	С1 (min)	С2 (max)	С3 (min)	С4 (max)
A+	0.103	0.138	0.102	0.149
A-	0.147	0.107	0.152	0.099

A+ = (0.103, 0.138, 0.102, 0.149)

A- = (0.147, 0.107, 0.152, 0.099)

Шаг 4: Расчет расстояний до идеального и наихудшего решений (евклидово расстояние)

$$S1+ = \sqrt{[(0.109 - 0.103)^2 + (0.138 - 0.138)^2 + (0.127 - 0.102)^2 + (0.132 - 0.149)^2]}$$

$$S2+ = 0.0490$$

$$S3+ = 0.0506$$

$$S4+ = 0.0744$$

$$S1- = 0.0642$$

$$S2- = 0.0563$$

$$S3- = 0.0705$$

$$S4- = 0.0380$$

Шаг 5: Расчет относительной близости к идеальному решению

$$C_i = S_i / (S_{i+} + S_{i-})$$

$$C1 = 0.0642 / (0.0308 + 0.0642) = 0.676$$

$$C2 = 0.535$$

$$C3 = 0.582$$

$$C4 = 0.338$$

Шаг 6: Расчет относительной близости к идеальному решению

Чем ближе значение C_i к 1, тем лучше альтернатива.

Вывод: Согласно методу TOPSIS, **наилучшим поставщиком является A1**. Он предлагает лучший компромисс между низкой ценой, высоким качеством, коротким сроком поставки и хорошей надежностью.

Поставщик	Относительная близость (C_i)	Ранг
A1	0.676	1
A3	0.582	2
A2	0.535	3
A4	0.338	4

ELECTRE и PROMETHEE

ELECTRE - метод порогов согласия и несогласия (Roy, 1968)

PROMETHEE — метод функций предпочтений (Brans, 1986)

Применение: стратегическое планирование, выбор площадок, экология.

ELECTRE (ELimination Et Choix Traduisant la REalité - исключение и выбор, отображающий действительность).

Семейство методов ELECTRE использует концепции согласия (concordance) и несогласия (discordance).

Альтернатива A превосходит B, если индекс согласия достаточно высок (A лучше B по большинству критериев) и индекс несогласия достаточно низок (нет критериев, по которым B значительно лучше A). Если сила аргументов "за" превышает порог согласия, и при этом нет ни одного "убийственного" аргумента "против" (превышающего порог несогласия), то мы говорим, что A outranks B (доминирование с учетом порогов).

Определение весов критериев: методы и проблемы

Методы прямого назначения весов

Простейший подход — прямое назначение весов экспертом.

Веса могут быть заданы в процентах (сумма 100%), баллах или рангах. Метод прост, но субъективен и подвержен когнитивным искажениям.

Пример: Менеджер проекта определяет веса критериев для выбора поставщика услуг облачного хостинга: надежность 35%, стоимость 30%, производительность 20%, качество поддержки 15%. Однако позже выясняется, что менеджер переоценил важность стоимости из-за недавнего перерасхода бюджета (эффект доступности). После обсуждения с командой и анализа стратегических приоритетов веса корректируются: надежность 40%, производительность 25%, стоимость 20%, поддержка 15%.

Метод попарных сравнений (Саати)

Используется в АНР: критерии сравниваются попарно по важности, веса вычисляются из собственного вектора матрицы сравнений. Метод более систематичен, чем прямое назначение, и включает проверку согласованности.

Методы, основанные на предпочтениях и trade-off

Метод Swing weights, trade-off анализ и метод SMART требуют оценки относительной ценности изменений по различным критериям. Эти методы помогают выявить истинные предпочтения через анализ компромиссов.

Определение весов критериев: методы и проблемы

Метод Swing weights

Помогает ЛПР (лицу, принимающему решение) **расставить приоритеты (веса)** между критериями, основываясь на **полезности улучшения** каждого критерия от "худшего" к

"лучшему" состоянию.

Идея: важность критерия определяется не его абсолютным значением, а тем, насколько ценным кажется ЛПР "размах" (swing) от наихудшей к наилучшей возможной оценке по этому критерию.

Пример: Выбор проекта для инвестирования в IT-компанию

Критерии:

- Прибыль (в млн 5) (от 0 до 10)
- Срок окупаемости (в годах) (от 5 до 1)
- Риск (по шкале от 1 до 10, где 1 - низкий риск, 10 - высокий)

1. Определяем наихудший и наилучший уровень по каждому критерию:

Прибыль: худший = 0, лучший = 10

Срок окупаемости: худший = 5, лучший = 1

Риск: худший = 10, лучший = 1

2. Представляем ситуацию, когда все критерии находятся на наихудшем уровне. Затем рассматриваем, какое улучшение одного критерия до наилучшего уровня наиболее ценно.

3. Присваиваем вес самому важному улучшению (самому ценному swing) равны 100. Допустим, наиболее важно улучшение Прибыли с 0 до 10. Вес = 100.

4. Оцениваем другие улучшения относительно первого

Улучшение Срока окупаемости с 5 до 1: насколько оно важно по сравнению с улучшением прибыли? Допустим, эксперт оценивает в 80. Тогда вес = 80

Улучшение Риска с 10 до 1: эксперт оценивает в 60. Тогда вес = 60.

5. Нормируем веса

Сумма весов = $100 + 80 + 60 = 240$.

Нормированные веса:

Прибыль: $100/240 = 0.417$

Срок окупаемости: $80/240 = 0.333$

Риск: $60/240 = 0.250$

Ответ: Веса критериев: Прибыль - 0.417, Срок окупаемости - 0.333, Риск - 0.250.

Trade-Off Analysis (анализ компромиссов)

Используется после формирования множества альтернатив для визуализации и понимания компромиссов, которые приходится делать при выборе между ними. Он отвечает на вопрос: "Чем я жертвую, выбирая один вариант вместо другого."

Идея: улучшение по одному критерию почти всегда достигается за счет ухудшения по другому. Trade-off анализ делает эти жертвы явными и количественными.

Пример:

Попарное сравнение альтернатив

Сравнивая две альтернативы, вы напрямую видите компромисс.

Пример: Ноутбук X и Ноутбук Y.

Ноутбук X: Цена 1000\$, Батарея 8 часов.

Ноутбук Y: Цена 1200\$, Батарея 12 часов.

Компромисс (Trade-Off): Выбирая Y вместо X, вы теряете 200\$, но получаете 4 дополнительных часа работы. Стоят ли эти 4 часа 200\$? Это и есть суть анализа.

Построение графиков компромиссов (Trade-Off Charts). Это самый наглядный способ. На графике по осям откладываются два ключевых конфликтующих критерия, а точки представляют альтернативы. (Пример графика: Цена/ Время работы от батареи)

Альтернативы: A (800\$, 4ч), B (1000\$, 8ч), C (1200\$, 12ч), D (1100\$, 6ч).

Анализ:

Альтернативы A, B, C образуют "Парето-фронт" (эффективную границу): чтобы получить больше часов работы, придется платить больше. Компромисс между этими точками неизбежен и оправдан.

Альтернатива D доминируема: она хуже, чем B (при той же цене меньше часов работы) и хуже, чем C (за те же часы работы просят большую цену). Выбор D был бы нерациональным компромиссом.

Принятие решения

Глядя на график, ЛПР может задать себе вопросы:

"Готов ли я заплатить на 200\$ больше, чтобы перейти с B на C и получить +4 часа работы?"

"Или, может, мне лучше выбрать A и сэкономить, смирившись с малым временем работы?"

Ответы на эти вопросы и являются результатом trade-off анализа.

Замечание

Ситуация называется **Парето-оптимальной** (или Парето-эффективной), когда невозможно улучшить положение одного участника (или один критерий), не ухудшив при этом положение хотя бы одного другого участника (или другого критерия). **Парето-фронт** — это множество всех Парето-оптимальных решений.

Задача: Выбор лучшего ноутбука. У нас два критерия, которые мы хотим максимизировать:

- Производительность (Performance) - баллы от 1 до 10.
- Время работы от батареи (Battery Life) - часы.

Шаг 1. Сбор данных

Допустим, у нас есть 6 ноутбуков

Ноутбук	A	B	C	D	E	F
Производительность	2	4	6	8	9	7
Время работы (ч)	12	9	8	5	3	4

Шаг 2. Попарное сравнение и поиск доминируемых решений

Мы ищем ноутбуки, которые доминируются другими. Ноутбук X доминирует ноутбук Y, если:

- X не хуже Y по всем критериям.
- X строго лучше Y хотя бы по одному критерию.

Анализ:

- C vs. B: C (6, 8) vs. B (4, 9). C лучше по производительности, но хуже по батарее. Никто никого не доминирует.
- C vs. F: C (6, 8) vs. F (7, 4). C лучше по батарее, но хуже по производительности. Никто никого не доминирует.
- B vs. A: B (4, 9) vs. A (2, 12). B лучше по производительности, но хуже по батарее. Никто никого не доминирует.

- D vs. F: D (8, 5) vs. F (7, 4). D лучше и по производительности, и по батарее! D доминирует F. Значит, F — доминируемое, неэффективное решение.

Проверим все, выявляя доминируемые решения:

- F доминируется D.
- A доминируется B? Нет, у A батарея намного лучше.
- E доминируется D? E (9, 3) vs. D (8, 5). E лучше по производительности, но сильно хуже по батарее. Никто никого не доминирует.
- В нашем примере доминируемым является только ноутбук F.

Шаг 3. Определение Парето-фронта

Парето-фронт — это все недоминируемые решения. То есть те, для которых не существует другого решения, которое было бы не хуже по всем критериям и строго лучше хотя бы по одному.

Недоминируемые ноутбуки: A, B, C, D, E. (F — доминируемый, его исключаем).

Шаг 4. Визуализация

Построим график:

- по оси X — Производительность.
- по оси Y — Время работы, и отметим все ноутбуки.

- A (2, 12) — высоко слева.
 - B (4, 9) — правее и ниже A.
 - C (6, 8) — еще правее.
 - D (8, 5) — еще правее и ниже.
 - E (9, 3) — самый правый и низкий.
 - F (7, 4) — находится правее C, но ниже D. Он находится "внутри" области, ограниченной точками C, D, E.
- Если мы соединим точки A, B, C, D, E, они образуют "границу" — это и есть Парето-фронт. Все решения, лежащие на этой линии, являются Парето-оптимальными. Точка F лежит внутри и справа от этой границы, она неэффективна.
- В идеальном процессе многокритериального решения эти методы используются вместе. Сначала с помощью Swing Weights определяются адекватные веса, отражающие предпочтения ЛППР. Затем, после расчета оценок альтернатив (например, по WSM), с помощью Trade-Off Analysis проводится финальная проверка и осмысленный выбор среди лучших вариантов.

Метод SMART

Пример: Выбор места для отпуска

Критерии:

- Стоимость (в S)
- Погода (баллы от 1 до 10)
- Развлечения (баллы от 1 до 10)
- Безопасность (баллы от 1 до 10)

1. Ранжируем критерии по важности:

Самый важный - Безопасность, затем Погода, затем Развлечения, затем Стоимость.

2. Присваиваем баллы самому важному критерию, например, 100.

- Безопасность: 100

3. Оцениваем остальные критерии относительно самого важного

Погода: насколько менее важна, чем Безопасность? Допустим, 80.

Развлечения: 60.

Стоимость: 50.

4. Нормируем веса:

Сумма баллов = $100 + 80 + 60 + 50 = 290$.

Веса:

- Безопасность: $100/290 = 0.345$
- Погода: $80/290 = 0.276$
- Развлечения: $60/290 \approx 0.207$

- Стоимость: $50/290 = 0.172$

Ответ: Веса критериев: Безопасность - 0.345, Погода - 0.276, Развлечения - 0.207, Стоимость - 0.172.

MCDA и ИИ

ML - оценка критериев

GA - оптимизация весов

Нейросети - выявление скрытых предпочтений

Нечеткая логика - работа с размытыми суждениями

Пример: Fuzzy TOPSIS для выбора поставщиков.

Кейс: Транспортная стратегия города

Критерии: экологичность, стоимость, социальная выгода, сроки

Метод: ANP-TOPSIS (гибридный)

Результат: оптимальный сценарий, учитывающий интересы жителей и администрации.

Ограничения MCDA

- Субъективность весов
- Чувствительность к нормировке
- Возможность манипулирования предпочтениями
- Необходимость прозрачности при интеграции с ИИ

ИСППР

Интеллектуальные системы поддержки принятия решений

Данные → ИИ-модель → Анализ вариантов → Рекомендация → Человеческое решение

Ключевые преимущества:

- Обработка больших объемов данных в реальном времени
 - Учет сотен факторов одновременно
- Минимизация человеческих ошибок
 - Постоянное обучение и адаптация

Важно: во всех случаях ИИ не заменяет человека полностью, а предоставляет аргументированные рекомендации, окончательное решение остается за специалистом.

Примеры

Пример 1. Кредитный скоринг

Данные → Feature Engineering → ML-модели → Интерпретация → Рекомендация
(Источники данных)

- Транзакционная история (6 месяцев)

- Кредитная история
 - Поведенческие паттерны (мобильный банк)
 - Социально-демографические данные
 - Макроэкономические индикаторы (ML-компоненты)
 - Градиентный бустинг (XGBoost) - основная модель
 - NLP-анализ текстовых полей заявки
 - Anomaly detection для выявления мошенничества
 - SHAP для интерпретации (Книга – Анализ поведенческих данных на R и Python Бюиссон Ф.: https://psv4.userapi.com/s/v1/d/0il6ZhiG5LwRcu9T5GJzr8Erk6z8yal53EqI3bl-3BIHe0L5UDXhRbnT5IBuAX_OnR2-dgD5-s-M_Hz9c6Er0ppbjpr0fov7NAWPNfRBjOwk_lhRsSzA-Q/Floran_Byuissou_Analiz_povedencheskikh_dannykh_na_R_i_Python.pdf) (Выход системы)
 - Кредитный рейтинг (650-850)
 - Вероятность дефолта (0-100%)
 - Рекомендуемый лимит кредита
 - Ключевые факторы решения
- Данные:** традиционные финансовые данные (кредитная история, доход, расходы) + альтернативные данные (история аренды, поведение в интернете, данные о образовании и работе).
- Процесс:
- Кандидат подает заявку онлайн.
 - Система собирает данные из различных источников (с согласия пользователя).
 - Модель ИИ вычисляет кредитный скоринговый балл (от 0 до 1000) и вероятность дефолта.
 - Система принимает предварительное решение: одобрить, отказать или отправить на дополнительную проверку.
 - Окончательное решение принимает кредитный офицер, который видит рекомендацию ИИ и *развернутую интерпретацию* (например, ключевые факторы, повлиявшие на решение).

Без использования ИИ

Ручная проверка кредитными офицерами

Простые правила: "Стаж > 2 года", "Зарплата > 60к"

Время принятия решения: 3-7 дней

Точность: 65-70% (высокий % ложных отказов)

Обработка: 50-100 заявок на офицера в день

С использованием ИИ

Время решения: 2-5 минут (автоматическое одобрение 40% заявок)

Точность: 85-90% (AUC-ROC = 0.89)

Увеличил одобрение надежных заемщиков с тонкой кредитной историей на 25%

Снизил дефолты на 18% за счет выявления скрытых паттернов риска

Персонализация: разные условия кредита для разных сегментов

Пример 2. Завод по производству автомобилей

Датчики → Edge Computing → Cloud Analytics → Dashboard → Рекомендации
(Источники данных)

- Вибрационные датчики.
- Термодатчики
- Камеры компьютерного зрения
- История ремонтов
- Данные о качестве продукции
(ML-компоненты)
- LSTM-сети для прогнозирования остаточного ресурса
- Random Forest для классификации типов неисправностей
- Computer Vision для автоматического осмотра
- Reinforcement Learning для оптимизации графика ТО
(Выход системы)
- Прогноз сбоя (вероятность + срок)
- Рекомендации по обслуживанию
- Приоритетность ремонтов
- Оптимальное время остановки линии

Данные: данные с датчиков оборудования (вибрация, температура, давление, ток двигателя) + журналы обслуживания + условия эксплуатации.

Процесс:

- Данные с датчиков в реальном времени передаются в облако.
- Модель ИИ анализирует данные и прогнозирует вероятность сбоя в ближайшие N часов/дней.
- Система генерирует оповещения для инженеров и рекомендует действия (например, заменить деталь, провести диагностику, продолжить работу).
- Инженер видит прогноз и рекомендацию, планирует обслуживание в наиболее подходящее время (например, во время планового простоя).

Без использования ИИ

Плановое ТО по расписанию (каждые 500 часов)
Реактивный ремонт после поломок
Среднее время простоя: 8-12 часов на инцидент
Затраты на ТО: 15% от производственного бюджета
Непредвиденные простои: 5-7% рабочего времени

С использованием ИИ

Снижение неплановых простоев на 67%
Увеличение времени безотказной работы с 89% до 96%
Сокращение затрат на ТО на 22%
Прогнозирование сбоев за 24-72 часа с точностью 84%
Оптимизация запасов запчастей (снижение на 30%)

Пример 3. Навигационные системы (карты)

Мультиспектральные данные → ИИ-обработка → Валидация → Обновление карт
(Источники данных)

- Спутниковые снимки (Sentinel, Landsat)
- GPS-треки миллионов устройств
- Камеры Street View
- Пользовательские отчеты
- Социальные медиа (геотеги)
(ML-компоненты)
- U-Net CNN для сегментации объектов
- Change detection algorithms
- Ensemble модели для классификации дорог
- Time series анализ для сезонных изменений
- Active learning для обработки спорных случаев
(Выход системы)
- Автоматически обновленные картографические слои
- Карта изменений (change map)
- Confidence score для каждого изменения
- Приоритеты для ручной проверки
- Рекомендации по сбору дополнительных данных

Данные: спутниковые снимки, данные GPS, пользовательские отчеты, социальные медиа.

Модель ИИ: сверточные нейронные сети (CNN) для обнаружения изменений на местности (новые здания, дороги, изменение ландшафта).

Процесс:

- Система регулярно загружает свежие спутниковые снимки.
- Модель ИИ сравнивает новые снимки с предыдущими и обнаруживает изменения.
- Изменения классифицируются (новая дорога, новое здание, разрушенное здание и т.д.).
- Система создает задание для картографов на проверку и внесение изменений в карту.
- Картограф проверяет автоматически размеченные изменения и подтверждает или отклоняет их.

Без использования ИИ

Ручная дигитализация картографами (процесс перевода в цифровой формат вручную)

Полевые исследования раз в 1-2 года

Время обновления карты: 6-18 месяцев

Точность: высокая в центре города, низкая в пригородах

Покрытие: только основные дороги и значимые объекты

С использованием ИИ

Частота обновлений: еженедельно (вместо ежегодно)

Автоматическое обнаружение 94% изменений инфраструктуры

Снижение затрат на поддержку актуальности карт на 60%

Обнаружение временных изменений (стройки, сезонные дороги)

Глобальное покрытие даже в удаленных регионах

Быстрое отображение новых дорог (в течение 2-4 недель)

Надо на 4 курсе 1 семестра до рассказать с 4 примера.